

Habilidades intermedias para analistas de datos

Introducción al análisis exploratorio de datos

En breve iniciamos

INTRODUCCIÓN AL ANÁLISIS EXPLORATORIO DE DATOS

Análisis exploratorio de datos

Metodologías: CRISP-DP


Gobierno de datos

Artefactos

Ejercicio aplicado

Al final de la clase de hoy

1. Conoceremos los conceptos base de Análisis Exploratorio de Datos (EDA)
2. Conoceremos los conceptos de gobierno de datos.
3. Podremos usar y crear artefactos de recopilación de información como diccionario de datos e inventario de fuentes.



ANÁLISIS EXPLORATORIO DE DATOS

¿Qué es el análisis exploratorio de datos?

Método utilizado para analizar y resumir conjuntos de datos.

Proceso que nos permite entender:

- El comportamiento individual de las variables,
- Las relaciones entre ellas,
- Detectar datos atípicos,
- Determinar cuáles técnicas pueden ser apropiadas para procesar los datos.

Cuáles técnicas son comunes

Visualización
univariada

Visualización
bivariada

Visualización
multivariada

Análisis de
correlación

Segmentación
(Clustering)


METODOLOGÍAS: CRISP-DM

Qué es CRISP - DM

CRoss Industry **S**tandard **P**rocess for
Data **M**ining

Proceso Estándar para Minería de
Datos Cross Industria.

Es una aproximación estándar que
permite reproducir procesos de
minería de datos.



[CRISP-DM: Towards a standard process model for data mining](#)

Cuáles son las actividades de CRISP-DM

- Determinar objetivos de negocio
- Evaluar situación
- Determine los objetivos del proceso
- Realice un plan de proyecto

Entendimiento de negocio

- Recopile los datos iniciales
- Describa los datos
- Explore los datos
- Verifique la calidad de los datos

Entendimiento de datos

- Selección de datos para exclusión/Inclusión
- Construya los datos
- Integre los datos
- Cambie el formato

Preparación de los datos

- Seleccione la técnica de modelado
- Construya el modelo
- Medición del modelo

Modelamiento

- Revisión del proceso
- Siguiendo pasos

Evaluación del modelo vs Criterio de éxito

- Plan de despliegue
- Plan de monitoreo y mantenimiento
- Reporte final
- Review del proyecto – documentación

Despliegue

GOBIERNO DE DATOS

Gobierno de datos

Los procesos de gobierno de datos usualmente están enmarcados dentro de las prácticas definidas por DAMA*

El gobierno de datos busca garantizar el desarrollo, ejecución y supervisión de planes, políticas, programas y prácticas, que entreguen, controlen, protejan y amplíen el valor de los activos de datos e información a través de su ciclo de vida.

[*DATA MANAGEMENT BODY OF KNOWLEDGE, SECOND EDITION](#)

Gobierno de datos

Los procesos de gobierno de datos se centran en los siguientes frentes:

Modelado y
diseño de datos

Almacenamiento
y Operaciones
de datos

Seguridad de
datos

Integraciones e
interoperabilidad

Gestores de
documentos y
contenido

Datos maestros y
de referencia

Metadatos

Calidad de datos

Arquitectura de
datos

[*DATA MANAGEMENT BODY OF KNOWLEDGE, SECOND EDITION](#)

ARTEFACTOS

Inventario de fuentes

Es una herramienta para identificar los principales repositorios de información que puede requerir un proyecto de datos.

Algunos de los campos que puede requerir:

- Id
- Título
- Descripción
- Propósito
- Dueño de los datos
- Temática/Palabras clave
- Frecuencia de actualización
- Tipo: (Imágenes, video, base de datos)
- Formato (Excel, csv, sql db, no sql db, etc)

Diccionario de datos

Recopila los principales campos que nos permiten tener un entendimiento de los campos en una fuente de datos

Algunos de los campos que puede requerir:

- Nombre del campo
- Descripción
- Tipo de dato (Alfanumérico, entero, fecha)

Ejercicio

- De datos.gov.co escoja un conjunto de datos de su interés
- Presente una **lista de actividades** que debe realizar con este conjunto de datos para: **Entendimiento de negocio, Entendimiento de datos, Preparación de datos**, Modelado, Evaluación, Despliegue
- Realice una estimación de esfuerzo (horas) para cada tarea. ¿Qué debería pasar (prerrequisitos, supuestos) para que los tiempos de cada actividad se cumplan?
- ¿Qué actividades recomendaría realizar dentro de un análisis exploratorio de datos?

Con todo esto...

1. Entendemos los conceptos de gobierno de datos y análisis exploratorio de datos
2. Podemos proponer artefactos propios para resolver problemas de datos.

